Vergleich von SQL-Anfragen: Theorie und Implementierung in Java

Robert Hartmann

Martin-Luther-Universität Halle-Wittenberg
Naturwissenschaftliche Fakultät III
Institut für Informatik

26. September 2013

Motivation

- Vergleich von SQL-Anfragen üblicherweise in der Lehre
- Übungsaufgaben notwendig für praktisches Verständnis von SQL
- Bestehend aus Sachaufgabe und Datenbankschema
- Lösung des Lernenden formuliert als SQL-Statement

Motivation

- Vergleich von SQL-Anfragen üblicherweise in der Lehre
- Übungsaufgaben notwendig für praktisches Verständnis von SQL
- Bestehend aus Sachaufgabe und Datenbankschema
- Lösung des Lernenden formuliert als SQL-Statement

semantische Äquivalenz

Zwei SQL-Anfragen sind semantisch äquivalent, wenn beide Anfragen auf allen Datenbankzuständen einer Datenbank stets die selben Tupel zurückliefern.

- Allgemein: Nicht entscheidbar
- Korrektur der Aufgabe auf zwei Arten: manuell oder automatisch

Manueller Vergleich

Vorteile

- Korrektur zuverlässig
- Syntaktische Varianten der Lösung werden erkannt
- Lernender erhält (potentiell) detailliertes Feedback

Nachteile

- Korrektur langsam
- Wenig Geld und Kürzungen in Lehre $\rightarrow$ Wenig Zeit zur Verfügung
- Unter Zeitdruck: Mehr Fehler, wenig detailliertes Feedback

Fazit: Manuelles Vergleichen funktioniert nur, wenn genug Mitarbeiter/ Hilfskräfte zur Verfügung stehen.

Automatischer Vergleich

Automatischer Vergleich zweier SQL-Anfragen wird üblicherweise durch den Vergleich der Ergebnistupel realisiert.

Vorteile

- Korrektur in Echtzeit
- Keine Mitarbeiter oder Hilfskräfte benötigt

Nachteile

- Für jedes Datenbankschema sind Daten notwendig
- Feedback für Lernenden oft unzureichend um Fehler zu identifizieren
- *false positive* leicht zu erstellen, System kann ausgehebelt werden
- *false positive* auch unabsichtlich problematisch: Lernender bemerkt Fehler nicht

Fazit: Automatisches Vergleichen durch bloßes Vergleichen von Ergebnistupeln nicht zuverlässig

Neuer Ansatz

- automatischer Vergleich mit Datenbankschema und Musterlösung
- sichere Rückmeldung benötigt Daten, Hauptteil aber ohne möglich

Neuer Ansatz

- automatischer Vergleich mit Datenbankschema und Musterlösung
- sichere Rückmeldung benötigt Daten, Hauptteil aber ohne möglich

Erster Schritt: **Standardisierung** (Prüfung: hinreichende Bedingung)
Ziel: Semantisch äquivalente Anfragen sollen nach der Standardisierung auch syntaktisch gleich sein

Neuer Ansatz

- automatischer Vergleich mit Datenbankschema und Musterlösung
- sichere Rückmeldung benötigt Daten, Hauptteil aber ohne möglich

Erster Schritt: **Standardisierung** (Prüfung: hinreichende Bedingung)
Ziel: Semantisch äquivalente Anfragen sollen nach der Standardisierung auch syntaktisch gleich sein

Zweiter Schritt: **Vergleich von Ergebnismengen** (Prüfung: notwendige Bedingung)
Ziel: Nachweis der Ungleichheit beider Anfragen

Neuer Ansatz

- automatischer Vergleich mit Datenbankschema und Musterlösung
- sichere Rückmeldung benötigt Daten, Hauptteil aber ohne möglich

Erster Schritt: **Standardisierung** (Prüfung: hinreichende Bedingung)
Ziel: Semantisch äquivalente Anfragen sollen nach der Standardisierung auch syntaktisch gleich sein

Zweiter Schritt: **Vergleich von Ergebnismengen** (Prüfung: notwendige Bedingung)
Ziel: Nachweis der Ungleichheit beider Anfragen

Dritter Schritt: **Struktureller Vergleich der Anfragen**
Ziel: genauere Lokalisierung von Fehlern des Lernenden

Überblick

- Standardisierung bildet ersten Schritt
- Entfernen von syntaktischen Details und Einlesen von Anfrage in Datenstruktur durch Parser
- Behandeln von einzelnen Teilen der SQL-Anfrage (`SELECT`, `FROM`, `WHERE`, `GROUP BY`, `ORDER BY`)
- Abarbeitung nicht streng hintereinander, da einige Teile abhängig sind
- Zusammensetzen der behandelten Teile zur standardisierten SQL-Anfrage

FROM-Teil

- Lexikographisches Sortieren der Tabellen
- Einführung künstlicher Tupelvariablen (TV) mit fortlaufender Nummerierung (a1,a2,...)
- TV auf gleicher Ebene erhalten gleichen Startwert für Iteration

FROM-Teil

- Lexikographisches Sortieren der Tabellen
- Einführung künstlicher Tupelvariablen (TV) mit fortlaufender Nummerierung (a1,a2,...)
- TV auf gleicher Ebene erhalten gleichen Startwert für Iteration

```
SELECT ename FROM emp
WHERE sal > (SELECT AVG(sal) FROM emp)
AND empno > (SELECT AVG(empno) FROM emp)
```

FROM-Teil

- Lexikographisches Sortieren der Tabellen
- Einführung künstlicher Tupelvariablen (TV) mit fortlaufender Nummerierung (a1,a2,...)
- TV auf gleicher Ebene erhalten gleichen Startwert für Iteration

```
SELECT ename FROM emp
WHERE sal > (SELECT AVG(sal) FROM emp)
AND empno > (SELECT AVG(empno) FROM emp)

SELECT ename FROM emp a1
WHERE sal > (SELECT AVG(sal) FROM emp a2)
AND empno > (SELECT AVG(empno) FROM emp a2)
```

SELECT-Teil

- Ersetzen von Wildcard (*) zu konkreten Spalten (vor Sortieren in `FROM`)
- Einführen der künstlichen TV als Aliase
- Wenn Spaltenreihenfolge unwichtig: lexikographisches Sortieren der Spalten

SELECT-Teil

- Ersetzen von Wildcard (*) zu konkreten Spalten (vor Sortieren in `FROM`)
- Einführen der künstlichen TV als Aliase
- Wenn Spaltenreihenfolge unwichtig: lexikographisches Sortieren der Spalten

```
SELECT ename FROM emp a1
WHERE sal > (SELECT AVG(sal) FROM emp a2)
AND empno > (SELECT AVG(empno) FROM emp a2)
```

SELECT-Teil

- Ersetzen von Wildcard (*) zu konkreten Spalten (vor Sortieren in `FROM`)
- Einführen der künstlichen TV als Aliase
- Wenn Spaltenreihenfolge unwichtig: lexikographisches Sortieren der Spalten

```
SELECT ename FROM emp a1
WHERE sal > (SELECT AVG(sal) FROM emp a2)
AND empno > (SELECT AVG(empno) FROM emp a2)

SELECT a1.ename FROM emp a1
WHERE a1.sal > (SELECT AVG(a2.sal) FROM emp a2)
AND a1.empno > (SELECT AVG(a2.empno) FROM emp a2)
```

WHERE-Teil - syntaktische Varianten

- Umwandeln des `WHERE`-Ausdrucks in KNF (konjunktive Normalform)

→ Erhöhung der Lesbarkeit, Eliminierung von unnötig tiefen Teilbäumen

Entfernung von syntaktischen Varianten:

WHERE-Teil - syntaktische Varianten

- Umwandeln des `WHERE`-Ausdrucks in KNF (konjunktive Normalform)

→ Erhöhung der Lesbarkeit, Eliminierung von unnötig tiefen Teilbäumen

Entfernung von syntaktischen Varianten:

- `a BETWEEN l AND u` **zu** `a >= l AND a <= u`
- `a >= ALL(c1, c2, c3)` **zu**
  `a >= c1 AND a >= c2 AND a >= c2`
- `a >= ANY(c1, c2, c3)` **zu**
  `a >= c1 OR a >= c2 OR a >= c2`
- `EXISTS (SELECT expr FROM ...)` **zu**
  `EXISTS (SELECT 1 FROM ...)`

WHERE-Teil - Arten von Operatoren

- `WHERE`-Ausdruck besteht im wesentlichen aus Operatoren, Konstanten und Spaltennamen
- Ordnung wird benötigt, damit semantisch äquivalente Anfragen auch syntaktisch gleich sind

WHERE-Teil - Arten von Operatoren

- `WHERE`-Ausdruck besteht im wesentlichen aus Operatoren, Konstanten und Spaltennamen
- Ordnung wird benötigt, damit semantisch äquivalente Anfragen auch syntaktisch gleich sind

Arten von Operatoren:

- Operatoren:
  `IS NULL, IS NOT NULL, EXISTS, ANY/SOME, ALL, ...`

→ keine syntaktischen Varianten möglich

- nicht-kommutative Operatoren: $\leq, \geq, <, >, -, /$

→ Hinzufügen aller Schreibweisen

- kommutative Operatoren: $=, <>, +, *, AND, OR$

→ Alle Permutationen der Operanden sind gültig → Festlegung einer Ordnung

Ordnung bei kommutativen Op

- Baum $T(x)$ mit Wurzel x. $children(x) = (c_1, c_2, ..., c_n)$
- Reihenfolge von $children(x)$ beliebig veränderbar

$\rightarrow$ Eindeutige Repräsentation erfordert Ordnung von $children(x)$

Ordnung bei kommutativen Op

- Baum $T(x)$ mit Wurzel x. $children(x) = (c_1, c_2, ..., c_n)$
- Reihenfolge von $children(x)$ beliebig veränderbar

$\rightarrow$ Eindeutige Repräsentation erfordert Ordnung von $children(x)$

- $order : children \rightarrow \mathbb{N}$
- Nach Sortieren gilt: $order(c_1) \leq order(c_2) \leq ...order(c_n)$

r	Spalte	Konstante	OR	$\leq$	$\geq$	$<$	$>$	$=$	$<>$	$+$	...
$order(r)$	1	2	3	4	5	6	7	8	9	10	11

- Vorgehen: BOTTOM-UP durch Rekursion

WHERE-Teil - Sortierung (2)

Beispiel:

`d = 5 OR a < 6` → `a < 6 OR d = 5`

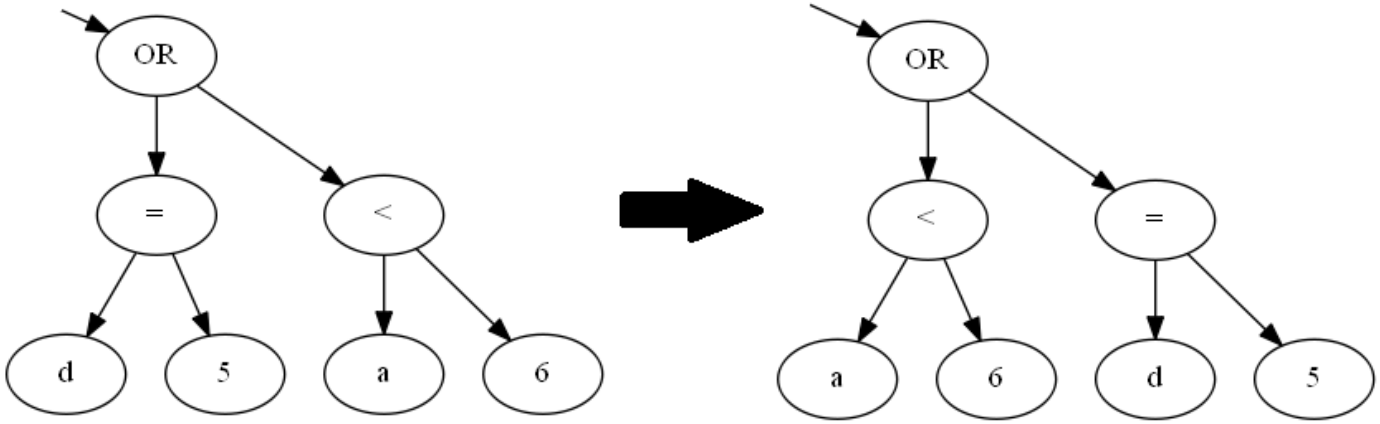

WHERE-Teil - Sortierung (2)

Beispiel:

`d = 5 OR a < 6` → `a < 6 OR d = 5`

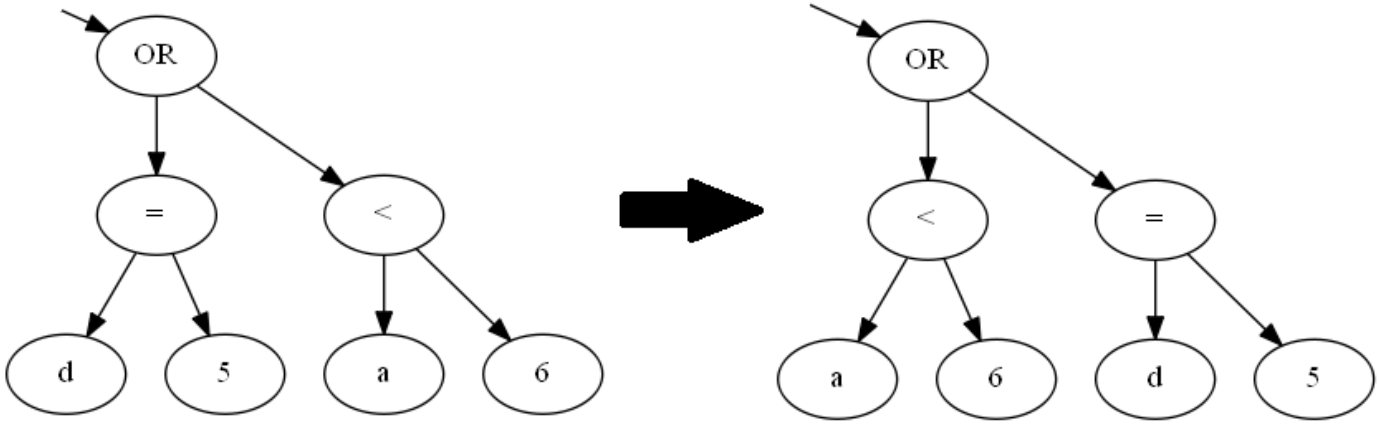

Problem: Was passiert, wenn zwei Kinder den gleichen Operator bezeichnen oder beide Kinder Spaltennamen bzw. Konstanten sind?

Beide Kindknoten bezeichnen gleichen Operator

Beispiel:

```
b = 2 OR c IS NULL and a < 6 OR d = 5 AND a > 5
```

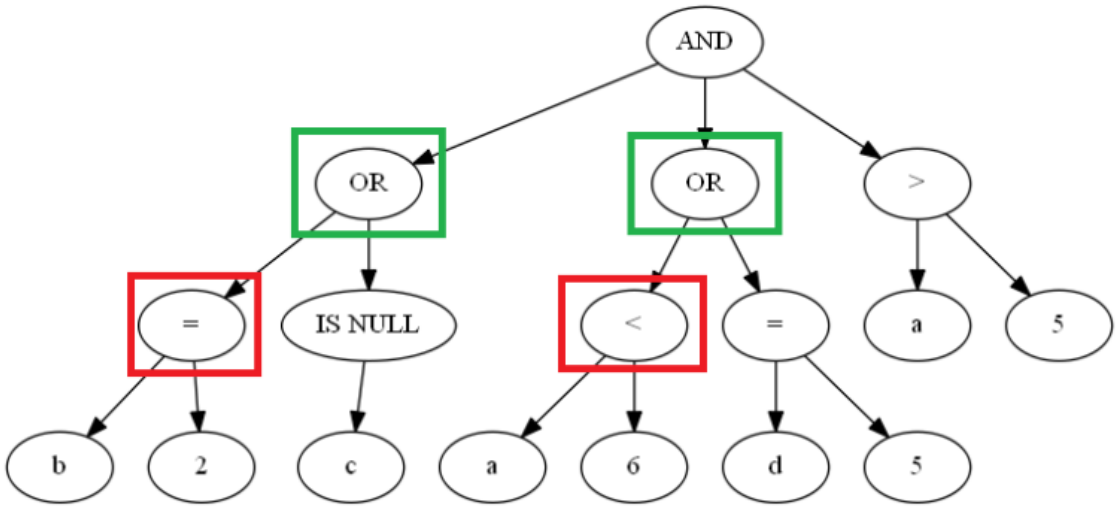

$\rightarrow$ Tauschen, da $order(=) = 8 > 6 = order(<)$

Beide Kindknoten bezeichnen gleichen Operator

- Situation: $order(c_i) = order(c_j)$ und c_i, c_j sind Operatoren ($j = i + 1$)

→ Schrittweise Tiefensuche auf $T(c_i), T(c_j)$ Aktuelle Knoten in DFS: v_i, v_j

- Wenn $v_i \neq v_j$ dann muss gelten: $order(v_i) < order(v_j)$, sonst Tauschen von c_i, c_j

Beispiel:

```
b = 2 OR c IS NULL and a < 6 OR d = 5 AND a > 5
```

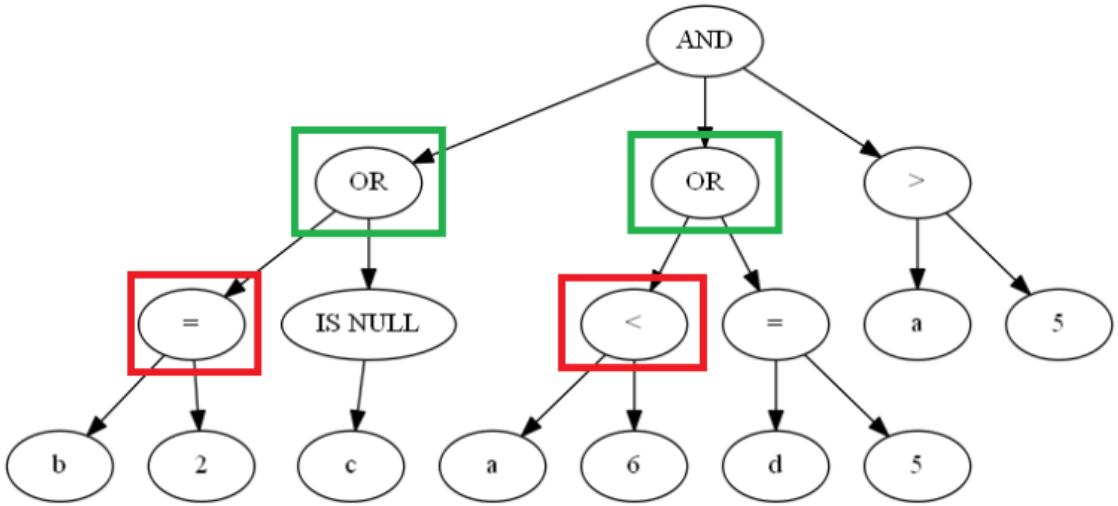

→ Tauschen, da $order(=) = 8 > 6 = order(<)$

Verbunde und Unterabfragen

- Äußere Verbunde ersetzt durch inneren Verbund verknüpft mit `UNION ALL`
- Natürliche Verbunde unter `FROM` als innere Verbunde unter `WHERE`
- Entfernen von Schlüsselwort `CROSS JOIN`
- Innere Verbunde unter `FROM` werden unter `WHERE` formuliert
- Umwandeln sämtlicher Unterabfragen zu `EXISTS`-Unterabfragen

Idee

- iterativer Vergleich beider Ergebnismengen nicht ohne weiteres möglich
- Problem: Optimierer des DBMS übernimmt Sortierung, wenn nicht explizit angegeben
- selbst mit expliziter Angabe: Sortierung nicht notwendigerweise eindeutig
- Beispiel:

```
SELECT surname, firstname
FROM people ORDER BY surname
```

Probleme:

Idee

- iterativer Vergleich beider Ergebnismengen nicht ohne weiteres möglich
- Problem: Optimierer des DBMS übernimmt Sortierung, wenn nicht explizit angegeben
- selbst mit expliziter Angabe: Sortierung nicht notwendigerweise eindeutig
- Beispiel:

```
SELECT surname, firstname
FROM people ORDER BY surname
```

Probleme:

- Falsche Lösung wird zufällig korrekt sortiert → falsche Übereinstimmung
- Korrekte Lösung wird falsch sortiert → keine Übereinstimmung

Fallunterscheidung (1)

- ML enthält kein `ORDER BY` → `ORDER BY` von LL streichen
- künstliche Sortierung nach Auswahlspalten, die unbenutzt sind
- iteratives Vorgehen

Beispiel:

```
SELECT firstname, surname FROM people
ORDER BY surname
```

Fallunterscheidung (1)

- ML enthält kein `ORDER BY` → `ORDER BY` von LL streichen
- künstliche Sortierung nach Auswahlspalten, die unbenutzt sind
- iteratives Vorgehen

Beispiel:

```
SELECT firstname, surname FROM people
ORDER BY surname
```

zu:

```
SELECT firstname, surname FROM people
ORDER BY surname, 1, 3
```

→ SQL-Anfrage nun auf jedem DBMS immer eindeutige Ausgabereihenfolge

Feedback

- Vergleich einzelner Teile der Anfrage (`SELECT, FROM, ...`)

→ Hinweis an Nutzer, welche Teile identisch mit ML sind (WO ist der Fehler?)

- Vergleich von Anzahl verschiedener Komponenten (Tabellen, Formeln, Verbunde, Unterabfragen)

→ konkreter Hinweis, WAS an der eigenen Lösung fehlt/überflüssig ist

- Vergleich mit Realdaten (Schritt 2) unterstützt verschiedene DBMS → verschiedene Fehlermeldung der DBMS beim Parsen mit DBMS-Parser

→ Kompatibilitätstest

Technische Details

Ergebnisse der Arbeit sollen in Form einer Lernplattform umgesetzt werden.

- Javaklassen per JSP als HTML-Seiten nutzbar

→ plattformunabhängig

- automatisches Build- und Deployskript per *ant*
- Parser: ZQL (Open Source)
- mögliche DBMS für Schritt 2: alle mit JDBC-Connector

Aufbau des Programms

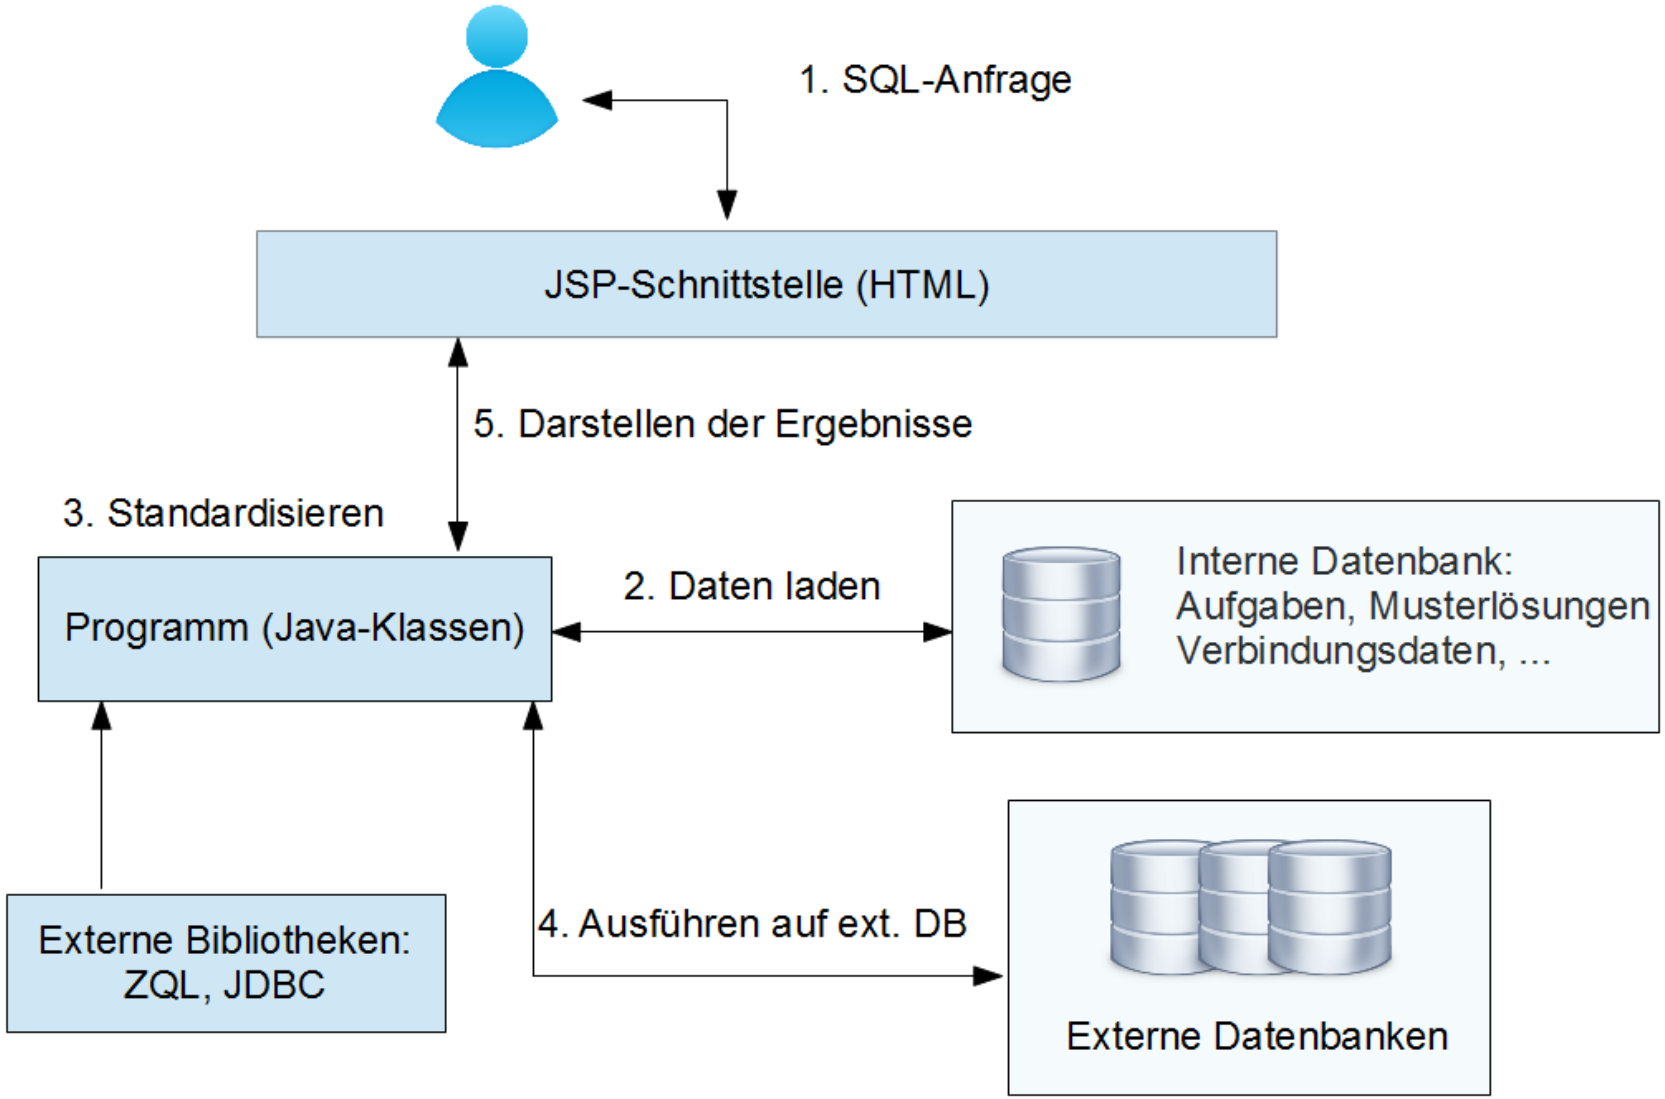

Einschränkungen in der Praxis / Probleme

- Nur Tabellen in `FROM` zugelassen (keine Verbunde, Unterabfragen)

→ keine Implementierung von (bereits ausgearbeiteten) Verbundskonzepten

- Parser versteht keine `CREATE TABLE`-Anweisungen

→ Kenntnis über Spalten (Name, Datentyp, Eigenschaften) notwendig

→ rudimentäres Parsen von `CREATE TABLE`-Anweisungen implementiert

- JDBC-Connector für DBMS zum Teil sehr unterschiedlich

→ Anbinden von neuen DBMS-Typen muss getestet werden

Fortsetzung

- Erweitern des Parsers
- → Umsetzen der Verbundskonzepte
- Erkennen von unnötigem `DISTINCT`
- Ausweitung auf Behandlung aller SQL-Ausdrücke (`UPDATE, DELETE`)
- Ausarbeitung und Implementierung weiterer Konzepte (zB: unnötige Verbunde, ...)
- transitiv-implizierte Formeln: `a = b AND a = 5` → `b = 5`
- Beschränkung der Domänen: `a > 2 AND a > 0` → `a > 2`