Vergleich von SQL-Anfragen: Theorie und Implementierung in Java

Robert Hartmann

Martin-Luther-Universität Halle-Wittenberg
Naturwissenschaftliche Fakultät III
Institut für Informatik

26. September 2013

- Vergleich von SQL-Anfragen üblicherweise in der Lehre
- Übungsaufgaben notwendig für praktisches Verständnis von SQL
- Bestehend aus Sachaufgabe und Datenbankschema
- Lösung des Lernenden formuliert als SQL-Statement
- Allgemein: Nicht entscheidbar
- Korrektur der Aufgabe auf zwei Arten: manuell oder automatisch
- Beide Ansätze haben signifikante Nachteile

Manueller Vergleich

Vorteile

- Korrektur zuverlässig
- Syntaktische Varianten der Lösung werden erkannt
- Lernender erhält (potentiell) detailliertes Feedback

Nachteile

- Korrektur langsam
- Wenig Geld und Kürzungen in Lehre $\rightarrow$ Wenig Zeit zur Verfügung
- Unter Zeitdruck: Mehr Fehler, wenig detailliertes Feedback

Fazit: Manuelles Vergleichen funktioniert nur, wenn genug Mitarbeiter/ Hilfskräfte zur Verfügung stehen.

Automatischer Vergleich

Automatischer Vergleich zweier SQL-Anfragen wird üblicherweise durch den Vergleich der Ergebnistupel realisiert.

Vorteile

- Korrektur in Echtzeit
- Keine Mitarbeiter oder Hilfskräfte benötigt

Nachteile

- Für jedes Datenbankschema sind Daten notwendig
- Feedback für Lernenden oft unzureichend um Fehler zu identifizieren
- *false positive* leicht zu erstellen, System kann ausgehebelt werden
- *false positive* auch unabsichtlich problematisch: Lernender bemerkt Fehler nicht

Fazit: Automatisches Vergleichen durch bloßes Vergleichen von Ergebnistupeln nicht zuverlässig

Neuer Ansatz (1)

- automatischer Vergleich mit Datenbankschema und Musterlösung
- sichere Rückmeldung benötigt Daten, Hauptteil aber ohne möglich

Erster Schritt: **Standardisierung**
Ziel: Semantisch äquivalente Anfragen sollen nach der Standardisierung auch syntaktisch gleich sein.

Zweiter Schritt: **Vergleich von Ergebnismengen**
Ziel: Nachweis der Ungleichheit beider Anfragen Dritter Schritt:

Struktureller Vergleich der Anfragen
Ziel: genauere Lokalisierung von Fehlern des Lernenden

Überblick

- Standardisierung bildet ersten Schritt
- Entfernen von syntaktischen Details und Einlesen von Anfrage in Datenstruktur durch Parser
- Behandeln von einzelnen Teilen der SQL-Anfrage (`SELECT`, `FROM`, `WHERE`, `GROUP BY`, `ORDER BY`)
- Abarbeitung nicht streng hintereinander, da einige Teile abhängig sind
- Zusammensetzen der behandelten Teile zur standardisierten SQL-Anfrage

FROM-Teil

- Lexikographisches Sortieren der Tabellen
- Sortierung: (1) Tabellen, (2) Unterabfragen, (3) Verbunde
- Einführung künstlicher Tupelvariablen (TV) mit fortlaufender Nummerierung (a1,a2,...)
- TV auf gleicher Ebene erhalten gleichen Startwert für Iteration

```
SELECT ename FROM emp
WHERE sal > (SELECT AVG(sal) FROM emp)
AND empno > (SELECT AVG(empno) FROM emp)

SELECT ename FROM emp a1
WHERE sal > (SELECT AVG(sal) FROM emp a2)
AND empno > (SELECT AVG(empno) FROM emp a2)
```

SELECT-Teil

- Ersetzen von Wildcard (*) zu konkreten Spalten (vor Sortieren in `FROM`
- Einführen der künstlichen TV als Aliase
- Wenn Spaltenreihenfolge unwichtig: lexikographisches Sortieren der Spalten

```
SELECT ename FROM emp a1
WHERE sal > (SELECT AVG(sal) FROM emp a2)
AND empno > (SELECT AVG(empno) FROM emp a2)

SELECT a1.ename FROM emp a1
WHERE a1.sal > (SELECT AVG(a2.sal) FROM emp a2)
AND a1.empno > (SELECT AVG(a2.empno) FROM emp a2)
```

WHERE-Teil - syntaktische Varianten

- Umwandeln des `WHERE`-Ausdrucks in KNF (konjunktive Normalform)

→ Erhöhung der Lesbarkeit, Eliminierung von unnötig tiefen Teilbäumen

Entfernung von syntaktischen Varianten:

- `a BETWEEN l AND u` **zu** `a >= l AND a <= u`
- `a IN (c1, c2, c3)` **zu** `a = c1 OR a = c2 OR a = c3`
- `a >= ALL(c1, c2, c3)` **zu**
  `a >= c1 AND a >= c2 AND a >= c2`
- `a >= ANY(c1, c2, c3)` **zu**
  `a >= c1 OR a >= c2 OR a >= c2`
- `EXISTS (SELECT expr FROM ...)` **zu**
  `EXISTS (SELECT 1 FROM ...)`

WHERE-Teil - Operatorenvielfalt (1)

Problem: Ausdrücke können unterschiedlich aufgeschrieben werden. Es ist nicht klar, welche Schreibweise der Lernende verwenden wird.
Beispiel: `a > 3` äquivalent zu `3 < a` und mit Zusatzwissen auch zu `a >= 2` und `2 <= a`

Ansatz 1: Hinzufügen aller äquivalenten Ausdrücke
Ansatz 2: Zulassen einer Repräsentation und Verbieten der restlichen Schreibweisen

Wir verfolgen den implementierten Ansatz 1.

WHERE-Teil - Operatorenvielfalt (2)

- Mengen M_i enthalten Muster, die äquivalente Schreibweisen beinhalten
- Passt atomare Formel A auf $m \in M_i \rightarrow$ Hinzufügen aller $m' \in M_i$ mit $m \neq m'$
- Vorgang wiederholen bis keine neuen Formeln hinzugefügt wurden
- Beispiel: `salary >= minsal`
- A, B: Konstanten oder Attribute, X: numerische Konstante
- $M_6 : \{ A \geq B, B \leq A \}$
- $\{ \quad \}$

WHERE-Teil - Operatorenvielfalt (2)

- Mengen M_i enthalten Muster, die äquivalente Schreibweisen beinhalten
- Passt atomare Formel A auf $m \in M_i \rightarrow$ Hinzufügen aller $m' \in M_i$ mit $m \neq m'$
- Vorgang wiederholen bis keine neuen Formeln hinzugefügt wurden
- Beispiel: `salary >= minsal`
- A, B: Konstanten oder Attribute, X: numerische Konstante
- $M_6 : \{ A \geq B, B \leq A \}$
- $\{ salary >= minsal, \}$

WHERE-Teil - Operatorenvielfalt (2)

- Mengen M_i enthalten Muster, die äquivalente Schreibweisen beinhalten
- Passt atomare Formel A auf $m \in M_i \rightarrow$ Hinzufügen aller $m' \in M_i$ mit $m \neq m'$
- Vorgang wiederholen bis keine neuen Formeln hinzugefügt wurden
- Beispiel: `salary >= minsal`
- A, B: Konstanten oder Attribute, X: numerische Konstante
- $M_6 : \{ A \geq B, B \leq A \}$
- $\{ salary >= minsal, minsal <= salary, \}$

WHERE-Teil - Sortierung (1)

- Baum $T(x)$ mit Wurzel x. $children(x) = (c_1, c_2, ..., c_n)$
- Eindeutige Repräsentation erfordert Ordnung von $children(x)$
- Ist x nicht-kommutativer Operator $\rightarrow$ Hinzufügen aller Schreibweisen
- Sonst: Ordnung von $children(x)$ beliebig veränderbar

$\rightarrow$ Ordnung muss definiert werden!

- $order : children \rightarrow \mathbb{N}$
- Nach Sortieren gilt: $order(c_1) \leq order(c_2) \leq ...order(c_n)$

r	Variable	Konstante	OR	$\leq$	$\geq$	$<$	$>$	$=$	$+$
$order(r)$	1	2	3	4	5	6	7	8	9

r	$-$	IS NULL	IS NOT NULL	EXISTS	ANY	ALL
$order(r)$	10	11	12	13	14	15

- Vorgehen: BOTTOM-UP durch Rekursion

WHERE-Teil - Sortierung (2)

Beispiel:

`d = 5 OR a < 6` → `a < 6 OR d = 5`

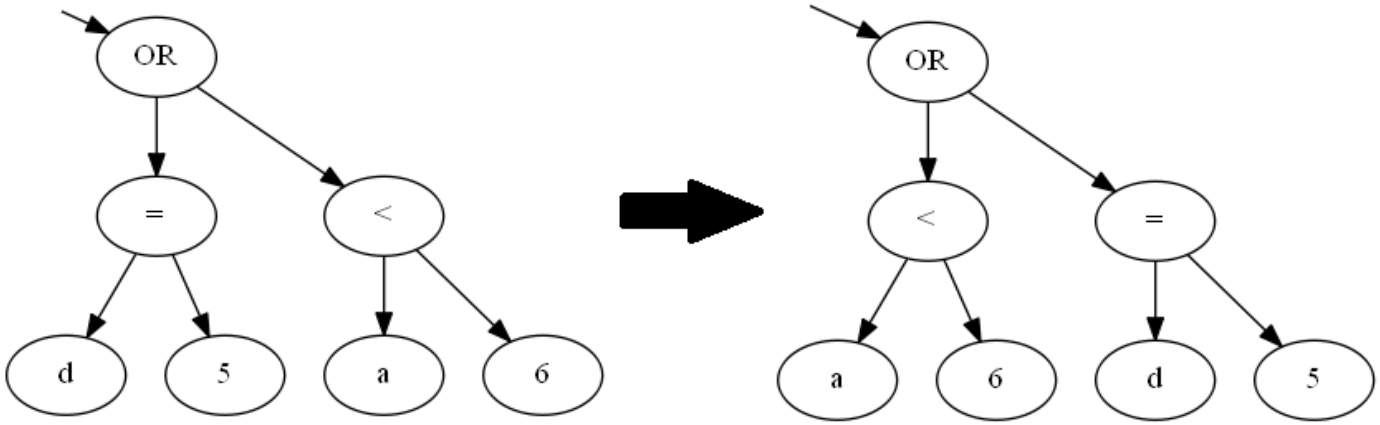

Problem: Was passiert, wenn zwei Kinder den gleichen Operator bezeichnen / beides Variablen / beides Konstanten sind?

WHERE-Teil - Sortierung (3)

Es sei $T(x)$ ein Parserbaum mit $children(x) = (c_1, c_2, ..., c_n)$. Haben wir $order(c_i) = order(c_{i+1})$ benötigen wir weiteres Kriterium für Bestimmung eindeutiger Ordnung. Wir benutzen schrittweise Tiefensuche, da alle Bäume unter c_i und c_j bereits sortiert sind.

- Es sei $order(c_i) = order(c_j)$ mit $j = i + 1$ und c_i, c_j sind beides keine Konstanten oder Variablen
- $DFS_i(x)$ bezeichnet aktuellen Knoten bei Tiefensuche auf Wurzelknoten x im Schritt i.

- for k=1 to n
  if ($DFS_k(c_j)$ == **NULL**) **AND** ($DFS_k(c_i)$!= **NULL**)
  swap(c_j,c_i);
  else if $order(DFS_k(c_j)) < order(DFS_k(c_i))$
  swap(c_j,c_i);
  return;
  endif
  endfor

WHERE-Teil - Sortierung (4)

Gilt $order(c_i) = order(c_j)$ mit $j = i + 1$ und c_i, c_j sind beides Konstanten oder Variablen, dann entscheidet lexikographische Sortierung.

Beispiel:

```
b = 2 OR c IS NULL and a < 6 OR d = 5 AND a > 5
```

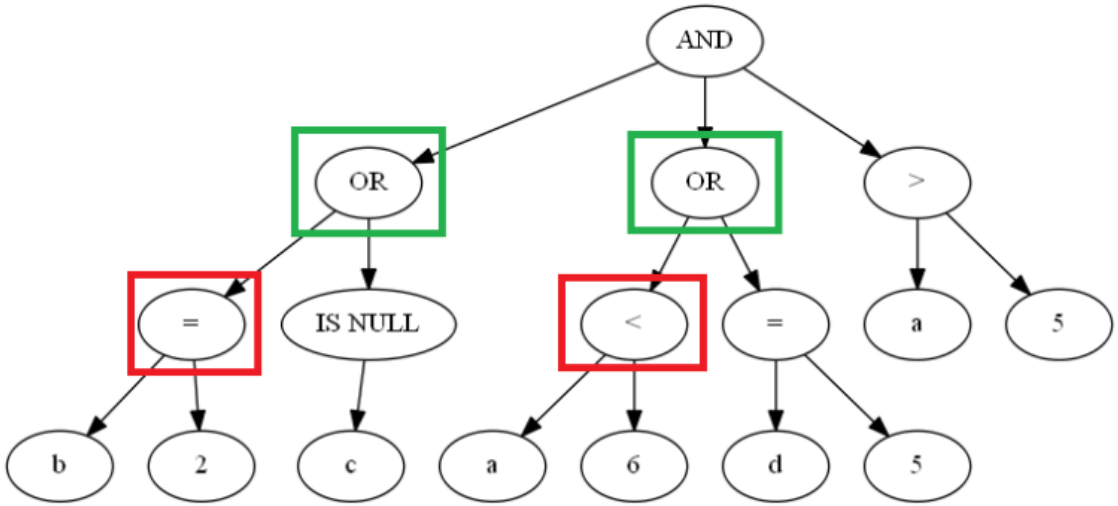

$\rightarrow$ Tauschen, da $order(=) = 8 > 6 = order(<)$

Letzter Schritt der Sortierung: Entfernung von Duplikaten.

GROUP BY und ORDER BY

GROUP BY:

- Einführen der künstlichen TV
- Lexik. Sortierung der `GROUP BY`-Items
- `HAVING BY` wie `WHERE` behandelt

ORDER BY:

- Ersetzen von Selektionsnummern
- Einführen der künstlichen TV

Verbunde und Unterabfragen

- Äußere Verbunde ersetzt durch inneren Verbund verknüpft mit `UNION ALL`
- Natürliche Verbunde unter `FROM` als innere Verbunde unter `WHERE`
- Entfernen von Schlüsselwort `CROSS`
- Innere Verbunde unter `FROM` werden unter `WHERE` formuliert
- Selbstverbunde: Erstellen von gültigen Permutationen und Hinzufügen zur standardisierten Lösung (i)
- Umwandeln sämtlicher Unterabfragen zu `EXISTS`-Unterabfragen (i)

Allgemeines

- Schritt nur notwendig, wenn Standardisierung fehlschlägt
- Prüfen der notwendigen Bedingung einer Äquivalenz zweier Anfragen
- Soll Ungleichheit nachweisen
- *false positive* nicht möglich
- reale Daten notwendig
- Vorgehen: Ausführen von Anfragen, Vergleich der Ergebnisse
- Unterstützte DBMS: abhängig von JDBC-Connector

Idee

- iterativer Vergleich beider Ergebnismengen nicht ohne weiteres möglich
- Problem: Optimierer des DBMS übernimmt Sortierung, wenn nicht explizit angegeben
- selbst mit expliziter Angabe: Sortierung nicht notwendigerweise eindeutig
- Beispiel:

```
SELECT surname, firstname
FROM people ORDER BY surname
```

→ Fallunterscheidung: Enthält Musterlösung (ML)/ Lösung des Lernenden (LL) `ORDER BY`?

Fallunterscheidung (1)

ML enthält kein `ORDER BY`, LL enthält `ORDER BY`

- Sortierung offensichtlich egal → zunächst Entfernung von `ORDER BY` von LL

ML enthält ein `ORDER BY`, LL enthält kein `ORDER BY`

- Sortierung von Bedeutung
- Lernende ist Sortierung offensichtlich egal
- Ziel: Nachweisen der Ungleichheit → keine Anpassungen
- Problem: zufällige Übereinstimmung

ML enthält kein `ORDER BY`, LL enthält `ORDER BY`

- keine Anpassung
- Problem: zufällige Übereinstimmung

Fallunterscheidung (2)

ML enthält kein `ORDER BY`, LL enthält kein `ORDER BY`

- Sortierung unwichtig, aber Optimierer bestimmt Ausgabe → kann Falschmeldungen erzeugen
- Lösung: Sortieren der Lösungen nach den Ausgabespalten (iterativ)
- Beispiel: `SELECT surname, firstname FROM people` zu:

```
SELECT surname, firstname
FROM people ORDER BY 1,2
```

Bei Fall 2 und 3 muss nachträglich nach allen unbenutzten Ausgabespalten sortiert werden. Selbst dann ist keine Eindeutigkeit gewährleistet. → offenes Problem.

Vergleich der Anfragen

- Vergleich einzelner Teile der Anfrage (`SELECT, FROM, ...`)

→ Hinweis an Nutzer, welche Teile identisch mit ML sind (WO ist der Fehler?)

- Vergleich von Anzahl verschiedener Komponenten (Tabellen, Formeln, Verbunde, Unterabfragen)

→ konkreter Hinweis, WAS an der eigenen Lösung fehlt/überflüssig ist

- Vergleich mit Realdaten (Schritt 2) unterstützt verschiedene DBMS → verschiedene Fehlermeldung der DBMS beim Parsen mit DBMS-Parser

→ Kompatibilitätstest

Technische Details

Ergebnisse der Arbeit sollen in Form einer Lernplattform umgesetzt werden.

- Javaklassen per JSP als HTML-Seiten nutzbar
- automatisches Build- und Deployskript per *ant*
- Parser: ZQL (Open Source)
- DBMS für Schritt 2: alle mit JDBC-Connector

Einschränkungen in der Praxis / Probleme

- Nur Tabellen in `FROM` zugelassen (keine Verbunde, Unterabfragen)

→ keine Implementierung von (bereits ausgearbeiteten) Verbundskonzepten

- Parser versteht keine `CREATE TABLE`-Anweisungen

→ Kenntnis über Spalten (Name, Datentyp, Eigenschaften) notwendig

→ rudimentäres Parsen von `CREATE TABLE`-Anweisungen implementiert

- JDBC-Connector für DBMS zum Teil sehr unterschiedlich

→ Anbinden von neuen DBMS-Typen muss getestet werden

Fortsetzung

- Erweitern des Parsers
- → Umsetzen der Verbundskonzepte
- komplexe arithmetische Ausdrücke
- Erkennen von unnötigem `DISTINCT`
- Ausweitung auf Behandlung aller SQL-Ausdrücke (`UPDATE, DELETE`)
- Ausarbeitung und Implementierung weiterer Konzepte (zB: unnötige Verbunde, ...)
- transitiv-implizierte Formeln: `a = b AND a = 5` → `b = 5`
- Beschränkung der Domänen: `a > 2 AND a > 0` → `a > 2`